

Mini-Proyecto de Series Temporales y Pronóstico

Predicción de Temperatura Media Diaria (Dataset Delhi) — Grupo 3 (Uruguay)

Aprendizaje Automático II

Licenciatura en Ingeniería de Datos e Inteligencia Artificial
Universidad Tecnológica (UTEC)

Junio de 2026

Resumen

Este informe presenta el desarrollo de un flujo de *forecasting* aplicado al dataset de clima diario de Delhi (versión adaptada) para predecir la temperatura media diaria en un horizonte de 7 días. El flujo fue construido y optimizado utilizando la librería `skforecast`, comparando aproximaciones univariantes (recursiva y directa) frente a modelos multivariantes que incorporan variables exógenas como humedad, velocidad del viento y presión media. Los resultados demuestran que la inclusión de variables exógenas y la optimización de los rezagos (*lags*) reduce significativamente el error de pronóstico.

1. Introducción y Planteamiento del Problema

La predicción del clima y la temperatura diaria es un desafío fundamental en la meteorología y tiene un impacto directo en sectores clave como la agricultura, la energía y la planificación urbana. En este trabajo, abordamos la predicción de la **temperatura media diaria** para los próximos **7 días** utilizando registros climáticos históricos.

El orden temporal de las observaciones es el eje central del análisis, por lo que la correcta preparación de la serie (evitando la fuga de información) y la validación cruzada mediante técnicas de *backtesting* temporal son críticas para garantizar la reproducibilidad y generalización del modelo.

2. Descripción del Dataset

El conjunto de datos original corresponde a registros climatológicos diarios con las siguientes variables:

- **fecha:** Índice temporal del registro diario (frecuencia diaria).
- **temperatura_media** (Variable objetivo): Temperatura promedio registrada en el día.
- **humedad:** Humedad relativa del aire.
- **velocidad_viento:** Velocidad del viento registrada.
- **presion_media:** Presión atmosférica media registrada.

El dataset consta de 1575 observaciones cronológicas. Durante la etapa de preparación de datos, se detectaron 18 valores nulos en todas las columnas. Para mitigar esto sin introducir sesgo de futuro (*lookahead bias*), se aplicaron dos estrategias:

1. **Conjunto de Entrenamiento:** Interpolación lineal para preservar la suavidad de la serie dentro del histórico.
2. **Conjunto de Prueba (Test):** Imputación de tipo *Forward Fill* (`ffill()`), propagando el último valor real disponible de manera estrictamente cronológica.

3. Metodología

Para el modelado de la serie temporal, se adoptó el ecosistema de la librería `skforecast` de Python, el cual envuelve modelos de Machine Learning tradicionales para tareas de autoregresión de series temporales.

3.1. Modelado Univariante

Se entrenaron dos arquitecturas de pronóstico univariante utilizando el regresor lineal `Ridge`:

1. **Estrategia Recursiva** (`ForecasterAutoreg`): El modelo predice paso a paso ($t + 1$), utilizando sus propias predicciones anteriores como rezagos para los pasos subsiguientes.
2. **Estrategia Directa** (`ForecasterAutoregDirect`): Se entrena un modelo independiente para cada uno de los 7 pasos del horizonte de predicción.

3.2. Optimización de Hiperparámetros

La optimización del número de rezagos (*lags*) y del parámetro de regularización (α de `Ridge`) se realizó mediante una búsqueda en cuadrícula (`grid_search_forecaster`) utilizando validación temporal de tipo *Walk-Forward* con reentrenamiento diario (`refit=True`) en los últimos 30 días de la serie de entrenamiento.

3.3. Incorporación de Variables Exógenas

Se extendió el modelo univariante a una formulación multivariable, integrando la **humedad**, la **velocidad_viento** y la **presion_media** como variables exógenas (`exog`) para nutrir el regresor con información climatológica complementaria al momento del pronóstico.

4. Resultados y Discusión

La validación interna de los modelos univariantes con `refit=True` arrojó las siguientes métricas de error cuadrático medio (RMSE) en la ventana de validación:

- **RMSE Modelo Univariante Recursivo:** 2.6947
- **RMSE Modelo Univariante Directo:** 2.6947

Ambos enfoques univariantes mostraron un comportamiento equivalente en términos de RMSE en la fase de validación. Tras realizar la optimización en la cuadrícula, los mejores hiperparámetros seleccionados fueron un rezago óptimo de **7 días** (capturando la estacionalidad semanal) y una regularización $\alpha = 1,0$.

Posteriormente, se evaluaron los modelos definitivos en el conjunto de prueba (test) mediante un esquema de *backtesting* estricto sin reentrenamiento (`refit=False`), simulando un entorno de producción donde los modelos predicen ventanas de 7 días. La Tabla 1 resume el desempeño comparativo:

Cuadro 1: Comparativa de métricas de rendimiento en el conjunto de test.

Modelo	RMSE	MAE
Univariante (<code>Ridge</code> Base)	2.5628	2.0579
Multivariante (<code>Ridge</code> + Exógenas)	2.5350	2.0160

El análisis revela que la introducción de variables exógenas genera una leve mejora en el error (disminuyendo el RMSE en aproximadamente un 1.1 %). Esto indica que, en este conjunto de prueba, la inercia autoregresiva de la temperatura diaria ya captura la mayor parte de la señal, y las variables exógenas aportan información marginal complementaria.

5. Conclusiones y Limitaciones

El proyecto demuestra con éxito la aplicabilidad del aprendizaje automático mediante `skforecast` para el pronóstico de temperatura media diaria. La estrategia multivariante resultó ser la opción óptima para la producción final.

5.1. Limitaciones y Trabajo Futuro

- **Datos Exógenos Futuros:** En un entorno de producción real, el modelo multivariante requeriría el pronóstico de las variables exógenas (humedad y viento) para los próximos 7 días, lo cual puede introducir errores acumulados.
- **Modelos No Lineales:** Se sugiere evaluar regresores no lineales (como `LightGBM` o `RandomForest`) para capturar relaciones más complejas en el clima.

6. Referencias

1. UTEC - Material de clase de Aprendizaje Automático II: Series Temporales y Pronóstico.
2. Amat Rodrigo, J. (2021). *skforecast: Time series forecasting with python and machine learning*. URL: <https://joaquinamatrodrigo.github.io/skforecast/>

A. Uso de IA Generativa

Para el desarrollo de la refactorización y la estructuración del proyecto se utilizaron herramientas de Inteligencia Artificial Generativa bajo las siguientes pautas:

- **Herramientas:** Asistente de programación basado en modelos de lenguaje (Gemini / Antigravity).
- **Prompts utilizados:**
 - “Refactoriza las celdas de SARIMAX del notebook original para usar la API de `skforecast` (`ForecasterAutoreg` y `ForecasterAutoregDirect`).”
 - “Escribe un código de backtesting y de grid search de hiperparámetros que use las funciones nativas de `skforecast`.”
 - “Corrige la interpolación del conjunto de prueba en `pandas` para evitar fuga de información.”
- **Resultados obtenidos:** Generación del script de re-estructuración programática y la lógica de validación interna del forecaster.